Fiche révision Apprentissage Statistique

Alexis GRACIAS

21 mars 2026

Table des matières

1 Modèle formel de l'apprentissage statistique supervisé 4
1.1 Définitions 4
1.2 Capacité d'apprentissage PAC 5
1.3 Convergence uniforme 5
1.4 Capacité d'apprentissage PAC pour des ensemble finis ($|\mathcal{H} < \infty$) . . 6
1.5 Dilemme biais / complexité (*underfitting vs. overfitting*) 6
1.6 Il n'existe pas d'aprocimateur universel 7

Notations

- $\mathcal{X}$ désigne l'ensemble des entrées (observations). $\mathcal{X}^m$ est l'ensemble des m-uplets $(x_1, \ldots, x_m)$ dont chaque terme est un élément de $\mathcal{X}$, on pose $\mathcal{X}^* = \bigcup_{m=1}^{+\infty} \mathcal{X}^m$. En d'autres tertmes,

$$\mathcal{X}^m = \left[x_1, \ldots, x_m\right] \quad x_i \in \mathcal{X}, \forall i \in \{1; m\}$$

$$\mathcal{X}^* = \bigcup_{m=1}^{+\infty} \mathcal{X}^m = \begin{bmatrix} x_{1,1} & \ldots & x_{1,m} \\ \vdots & \ldots & \vdots \\ x_{n,1} & \ldots & x_{n,m} \end{bmatrix}$$

- $|\mathcal{X}|$ désigne le cardinal de $\mathcal{X}$

- $\mathcal{Y}$ désigne l'espace des sorties. On a aussi $\mathcal{Y}^m$ est l'ensemble des m-uplets $(y_1, \ldots, y_m)$ dont chaque terme est un élément de $\mathcal{Y}$, on pose $\mathcal{Y}^* = \bigcup_{m=1}^{+\infty} \mathcal{Y}^m$. Il vient :

$$S = ((x_i, y_i)_{i \in \{1;m\}}) \in (\mathcal{X} \times \mathcal{Y})^*$$

- L désigne la fonction de coût

- $m(\mathcal{X}, \mathcal{Y})$ est l'ensemble des fonctions mesurables [1]

- $m_{\mathcal{H}}(\epsilon, \delta)$ est la fonction de complexité d'échantilon.

- $(ERM)_S$ est l'hypothèse qui minimise le risque empirique sur S, i.e.,

$$(ERM)_{\mathcal{H}}(S) = A(S) = h_S = \arg\min_{h \in \mathcal{H}} \mathcal{R}_S(h)$$

  C'est la meilleure hypothèse pour le *dataset* S.

- $(\Omega, \mathcal{E}, \mathbb{P})$ désigne un espace probabilisé

- $\mathbf{A}$ désigne une matrice.

- $\mathcal{M}_{n,p}(\mathbb{K})$ désigne l'espace des matrices de n lignes, p colonnes à coefficients dans $\mathbb{R}$

1. $(\mathcal{X}, m_{\mathcal{X}})$ et $(\mathcal{Y}, m_{\mathcal{Y}})$ sont des espaces mesurables

Rappels

1 Modèle formel de l'apprentissage statistique supervisé

1.1 Définitions

- Soient $\mathcal{X}, \mathcal{Y}$ donnés. La fonction de coût L est définie par :

$$\begin{aligned} L : \mathcal{Y} \times \mathcal{Y} &\to \mathbb{R}^+ \\ (y, y') &\mapsto L(y, y') \end{aligned}$$

  C'est une fonction arbitraire. En général, on prend $L(y, y') = |y - y'|^2$ (méthode OLS) avec $y' = \hat{y} = h(x)$, h l'hypothèse que l'on fait sur $x \in \mathcal{X}$ pour estimer la valeur y i.e. $\hat{y}$ est un estimateur de y. L est donc le coût de décision de h sur x.

- $h \in \mathcal{H} \subset m(\mathcal{X}, \mathcal{Y})$ avec $\mathcal{H}$ l'ensemble des hypothèses faites sur x pour estimer y.

- $S = ((x, y_i))_{1 \leq i \leq m} = ((x_1, y_1), \ldots, (x_m, y_m)) \in (\mathcal{X} \times \mathcal{Y})^*$ est une séquence d'objets labellisés. Les x_i sont les données observées et les y_i les valeurs à estimées. S représente le jeu de données d'entraînement

- Un Algorithme Automatique Supervisé (AAS) est une fonction tel que :

$$\begin{aligned} A : (\mathcal{X} \times \mathcal{Y})^* &\to \mathcal{H} \\ S &\mapsto A(S) = h_s \end{aligned}$$

- Risque réel :

$$\begin{aligned} \mathcal{R}(h) &= \mathbb{E}[L(y, y')] \\ &= \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) p(x, y) dx dy \\ &= \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) p(y|x) p(x) dx dy \end{aligned} \tag{1.1}$$

- Risque empirique :

$$\mathcal{R}_s(h) = \hat{\mathcal{R}}(h) = \frac{1}{m} \sum_{i=1}^{m} L(h(x_i), y_i) \tag{1.2}$$

C'est le seul risque dont on a accès (quantité d'information disponible limitée et finie). On cherche à minimiser le risque réel $\mathcal{R}$ à l'aide de la décision prise parmis $\mathcal{H}, h_s = A(S)$, à savoir :

$$\mathcal{R}(h_s) = \min_{h\in\mathcal{H}} \mathcal{R}(h) \Longleftrightarrow (\text{ERM})_{\mathcal{H}} = h_s \in \arg\min_{h\in\mathcal{H}} \mathcal{R}_s(h) \tag{1.3}$$

Propriété : $h \in \mathcal{H}, \mathcal{R}_s(h) \xrightarrow[m\to\infty]{p.s.} \mathcal{R}(h)$ et en moyenne quadratique. [1]

1.2 Capacité d'apprentissage PAC

Soient $\mathcal{X}, \mathcal{Y}, L, \mathcal{H}$ fixés. $\mathcal{H}$ a la capacité PAC [2] quand $\exists A, \exists m_{\mathcal{H}} :]0;1[^2 \to \mathbb{N}, \forall P, \forall(\epsilon,\delta) \in]0;1[^2, \forall m \geq m_{\mathcal{H}}(\epsilon,\delta), \forall S$

$$P(\mathcal{R}(A(S)) - \min_{h\in\mathcal{H}} \mathcal{R}(h) \leq \epsilon) \geq 1-\delta \Longleftrightarrow P(\mathcal{R}(h_S) - \min_{h\in\mathcal{H}} \mathcal{R}(h) \leq \epsilon) \geq 1-\delta \quad (*)$$

De même :

$$m_{\mathcal{H}}(\epsilon,\delta) = \min\{m \in \mathbb{N} \quad \text{tel que} \quad \forall P, \forall S, \quad (*) \text{ est vérifiée}\} \tag{1.4}$$

$m_{\mathcal{H}}(\epsilon,\delta)$ est la taille minimale du *dataset* qui permet à l'algorithme d'apprendre correctement. C'est la fonction de complexité de $\mathcal{H}$ en mémoire ou en échantilon (données). Plus $\mathcal{H}$ est complexe, plus il faut de données. De même, plus ϵ, δ sont petits, plus il faut de données. Si ϵ et δ sont petits, cela veut dire que l'algorithme retourne un bon modèle avec une grande probabilité. En général, pour une classe de VC-dimension d, on prend $m_{\mathcal{H}}(\epsilon,\delta) \approx \frac{d+log(\frac{1}{\delta})}{\epsilon}$

Propriété : Soit $\epsilon > 0$, S est **ϵ-représentatif** si et seulement si pour $h_s = (ERM)_{\mathcal{H}}(S)$,

$$\mathcal{R}(h_s) - \min_{h\in\mathcal{H}} \mathcal{R}(h) \leq \epsilon \tag{1.5}$$

1.3 Convergence uniforme

$\mathcal{H}$ a la propriété de convergence uniforme quand $\exists m_{\mathcal{H}}^{CU} \in]0;1[^2 \to \mathbb{N}, \forall P, \forall(\epsilon,\delta) \in]0;1[^2, \forall m \geq m_{\mathcal{H}}^{CU}(\epsilon,\delta), \forall S,$

$$P(\text{S est espilon-représentatif}) \geq 1-\delta \Longleftrightarrow P(\sup_{h\in\mathcal{H}} |\mathcal{R}(h) - \mathcal{R}_S(h)| \leq \epsilon) \geq 1-\delta \quad (**)$$

Propriété : Si $\mathcal{H}$ a la propriété de CU avec $m_{H_{CU}}^{CU}$ alors $\mathcal{H}$ a la capacité PAC par $A = (ERM)_{\mathcal{H}}$ et

$$m_H(\epsilon,\delta) \leq m_H^{CU}(\frac{\epsilon}{2},\delta) \tag{1.6}$$

1. Attention : $A(S)$ est une variable aléatoire donc $\mathcal{R}(A(S)) = \mathcal{R}(h_s)$ est une VA fonction de S, on ne peut pas appliquer la loi des grands nombres.

2. Probablement Approximativement Correct. Probablement car la probabilité de l'évènement est non négligeable ($\geq 1-\delta$), Approximativement car le minimum global n'est pas atteint mais il s'en rapproche d'une distance au plus ϵ ($\geq \epsilon$)

1.4 Capacité d'apprentissage PAC pour des ensemble finis ($|\mathcal{H} \ < \infty$)

Lemme d'Hoeffding (1962) : pour $(X_i)_{1\geq i\geq m}$ VA i.i.d., $\mathbb{E}[X_i] = \mu, \exists a < b, a, b \in, \mathbb{R}$ tel que $P(X_i \in [a; b]) = 1$, alors, $\forall \epsilon > 0$,

$$P(|\frac{1}{m}\sum_{i=1}^{m} X_i - \mu|) \leq 2e^{\frac{-2m\epsilon^2}{(b-a)^2}} \tag{1.7}$$

On appelle cette inégalité inégalité de concentration. D'après Hoeffding, on a que $\mathcal{H}$ a la propriété de CU SSI :

$$m_{\mathcal{H}}^{CU}(\epsilon, \delta) \leq \left\lceil \frac{\log\left(\frac{2|\mathcal{H}|}{\delta}\right)}{2\epsilon^2} \right\rceil \tag{1.8}$$

et donc $\mathcal{H}$ a la capacité PAC avec $m_{\mathcal{H}}(\epsilon, \delta) \geq \left\lceil \frac{2\log(\frac{2|\mathcal{H}|}{\delta})}{\epsilon^2} \right\rceil$

1.5 Dilemme biais / complexité (*underfitting vs. overfitting*)

Pour certains algorithmes comme les K plus proches voisins, la complexité devient énorme, ce qui nous pousse à trouver un équilibre entre la quantité de données disponibles et la performance du modèle.

$$\mathcal{R}(h_S) = \underbrace{\mathcal{R}(h_S) - \min_{h\in\mathcal{H}} \mathcal{R}(h)}_{\epsilon \text{ d'estimation}} + \underbrace{\min_{h\in\mathcal{H}} \mathcal{R}(h)}_{\epsilon \text{ approx.}} \tag{1.9}$$

$$\downarrow \qquad\qquad \downarrow$$

variance biais

- Si $|\mathcal{H}|$ est trop petit, l'espace des hypothèses n'est pas assez complexe pour trouver une hypothèse qui apprend bien les données (*underfitting*). Dans ce cas, le **biais** $\searrow$ **et la variance** $\nearrow$

- Si $|\mathcal{H}|$ est trop grand, l'espace des hypothèses est très complexe et peut coller parfaitement aux données ($\mathcal{R}_S(h) \to 0$) mais généralise mal (*overfitting*). Il a aussi besoin de plus de données. Dans ce cas, le **biais** $\nearrow$ **et la variance** $\searrow$

1.6 Il n'existe pas d'aprocimateur universel

Lemme 1 : Soit $m \in \mathbb{N}^*$, si $|\mathcal{X}| \leq 2m$ et $\mathcal{H} \in \mathcal{M}(\mathcal{X}, \mathcal{Y})$, alors $\forall A \in \mathcal{H}$ AAS, $\exists \mathbb{P}$ sur $\mathcal{X} \times \mathcal{Y}$ tel que :

$$\exists f \in \mathcal{H}, \quad \mathcal{R}(f) = 0$$

$$\forall S \in (\mathcal{X} \times \mathcal{Y})^* i.i.d., \quad \mathbb{E}[\mathcal{R}(S)] \geq \frac{1}{4}$$

No free lunch theorem : Avec les hypothèses du lemme précédent et $\forall A \in \mathcal{H}$ AAS, $\exists \mathbb{P}$ sur $\mathcal{X} \times \mathcal{Y}$

$$\exists f \in \mathcal{H}, \quad \mathcal{R}(f) = 0$$

$$\forall S \in (\mathcal{X} \times \mathcal{Y})^* i.i.d., \quad \mathbb{P}(\mathcal{R}[A(S)] \geq \frac{1}{8}) \geq \frac{1}{7}$$

1.7 Dimension VC (Vapnik-Chervonenkis)