Fiche révision Apprentissage Statistique

Alexis GRACIAS

16 mars 2026

Table des matières

1 Modèle formel de l'apprentissage statistique supervisé 4
1.1 Définitions 4
1.2 Capacité d'apprentissage PAC 5

Notations

- $\mathcal{X}$ désigne l'ensemble des entrées (observations). $\mathcal{X}^m$ est l'ensemble des m-uplets $(x_1, \ldots, x_m)$ dont chaque terme est un élément de $\mathcal{X}$, on pose $\mathcal{X}^* = \bigcup_{m=1}^{+\infty} \mathcal{X}^m$
- $|\mathcal{X}|$ désigne le cardinal de $\mathcal{X}$
- $\mathcal{Y}$ désigne l'espace des sorties
- L désigne la fonction de coût
- $m(\mathcal{X}, \mathcal{Y})$ est l'ensemble des fonctions mesurables [1]
- $(\Omega, \mathcal{E}, \mathbb{P})$ désigne un espace
- $\mathbf{A}$ désigne une matrice.
- $\mathcal{M}_n, p(\mathbb{K})$ désigne l'espace des matrices de n lignes, p colonnes à coefficients dans $\mathbb{R}$

1. $(\mathcal{X}, m_{\mathcal{X}})$ et $(\mathcal{Y}, m_{\mathcal{Y}}$ sont des espaces mesurables)

Rappels

1 Modèle formel de l'apprentissage statistique supervisé

1.1 Définitions

- Soient $\mathcal{X}, \mathcal{Y}$ donnés. La fonction de coût L est définie par :

$$\begin{aligned} L : \mathcal{Y} \times \mathcal{Y} &\to \mathbb{R}^+ \\ (y, y') &\mapsto L(y, y') \end{aligned}$$

  C'est une fonction arbitraire. En général, on prend $L(y, y') = |y - y'|^2$ (méthode OLS) avec $y' = \hat{y} = h(x)$, h l'hypothèse que l'on fait sur $x \in \mathcal{X}$ pour estimer la valeur y i.e. $\hat{y}$ est un estimateur de y. L est donc le coût de décision de h sur x.

- $h \in \mathcal{H} \subset m(\mathcal{X}, \mathcal{Y})$ avec $\mathcal{H}$ l'ensemble des hypothèses faites sur x pour estimer y.

- $S = ((x, y_i))_{1 \leq i \leq m} = ((x_1, y_1), \ldots, (x_m, y_m)) \in (\mathcal{X} \times \mathcal{Y})^*$ est une séquence d'objets labellisés. Les x_i sont les données observées et les y_i les valeurs à estimées. S représente le jeu de données d'entraînement

- Un Algorithme Automatique Supervisé (AAS) est une fonction tel que :

$$\begin{aligned} A : (\mathcal{X} \times \mathcal{Y})^* &\to \mathcal{H} \\ S &\mapsto A(S) = h_s \end{aligned}$$

- Risque réel :

$$\begin{aligned} \mathcal{R}(h) &= \mathbb{E}[L(y, y')] \\ &= \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) p(x, y) dx dy \\ &= \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) p(y|x) p(x) dx dy \end{aligned} \tag{1.1}$$

- Risque empirique :

$$\mathcal{R}_s(h) = \hat{\mathcal{R}}(h) = \frac{1}{m} \sum_{i=1}^{m} L(h(x_i), y_i) \tag{1.2}$$

C'est le seul risque dont on a accès (quantité d'information disponible limitée et finie). On cherche à minimiser le risque réel $\mathcal{R}$ à l'aide de la décision prise parmis $\mathcal{H}, h_s = A(S)$, à savoir :

$$\mathcal{R}(h_s) = \min_{h \in \mathcal{H}} \mathcal{R}(h) \Longleftrightarrow (\text{ERM})_{\mathcal{H}} = h_s \in \arg\min_{h \in \mathcal{H}} \mathcal{R}_s(h) \tag{1.3}$$

Propriété : $h \in \mathcal{H}, \mathcal{R}_s(h) \xrightarrow[m \to \infty]{p.s.} \mathcal{R}(h)$ et en moyenne quadratique. [1]

1.2 Capacité d'apprentissage PAC

Soient $\mathcal{X}, \mathcal{Y}, L, \mathcal{H}$ fixés. $\mathcal{H}$ a la capacité PAC [2] quand :

$$\exists A, \exists m_{\mathcal{H}} :]0;1[^2 \to \mathbb{N}, \forall P, \forall (\epsilon, \delta) \in]0;1[^2, \forall m \leq m_{\mathcal{H}}(\epsilon, \delta), \forall S = ((x, y_i))_{1 \leq i \leq m} = ((x_1, y_1), \ldots, (x_m, y_m)),$$

$$P(\mathcal{R}(A)(S) - \min_{h \in \mathcal{H}} \mathcal{R}(h) \leq \epsilon) \geq 1 - \delta \quad (*)$$

De même :

$$m_{\mathcal{H}}(\epsilon, \delta) = \min\{m \in \mathbb{N} \text{tel que} \forall P, \forall S, (*) \text{est vérifiée}\} \tag{1.4}$$

1. Attention : $\mathcal{R}(h_s)$ est une VA fonction de S, on ne peut pas appliquer la loi des grands nombres.
2. Probablement Approximativement Correct