Fiche révision Apprentissage Statistique

Alexis GRACIAS

25 mars 2026

Table des matières

1 Modèle formel de l'apprentissage statistique supervisé 4
1.1 Définitions générales 4
1.2 Capacité d'apprentissage PAC 5
1.2.1 Définition 5
1.2.2 Convergence uniforme 6
1.2.3 Capacité d'apprentissage PAC pour des ensemble finis ($|\mathcal{H}| < \infty$) 6
1.2.4 Capacité d'apprentissage PAC faible 6
1.3 Dilemme biais / complexité (*underfitting vs. overfitting*) 7
1.3.1 Définition 7
1.3.2 Il n'existe pas d'aprocimateur universel 7
1.4 Dimension VC (Vapnik-Chervonenkis) 8
1.4.1 Définitions 8

Notations

- $\mathcal{X}$ désigne l'ensemble des entrées (observations). $\mathcal{X}^m$ est l'ensemble des m-uplets $(x_1, \ldots, x_m)$ dont chaque terme est un élément de $\mathcal{X}$, on pose $\mathcal{X}^* = \bigcup_{m=1}^{+\infty} \mathcal{X}^m$. En d'autres tertmes,

$$\mathcal{X}^m = \left[x_1, \ldots, x_m\right] \quad x_i \in \mathcal{X}, \forall i \in \{1; m\}$$

$$\mathcal{X}^* = \bigcup_{m=1}^{+\infty} \mathcal{X}^m = \begin{bmatrix} x_{1,1} & \ldots & x_{1,m} \\ \vdots & \ldots & \vdots \\ x_{n,1} & \ldots & x_{n,m} \end{bmatrix}$$

- $|\mathcal{X}|$ désigne le cardinal de $\mathcal{X}$

- $\mathcal{Y}$ désigne l'espace des sorties. On a aussi $\mathcal{Y}^m$ est l'ensemble des m-uplets $(y_1, \ldots, y_m)$ dont chaque terme est un élément de $\mathcal{Y}$, on pose $\mathcal{Y}^* = \bigcup_{m=1}^{+\infty} \mathcal{Y}^m$. Il vient :

$$S = ((x_i, y_i)_{i \in \{1;m\}}) \in (\mathcal{X} \times \mathcal{Y})^*$$

- L désigne la fonction de coût

- $m(\mathcal{X}, \mathcal{Y})$ est l'ensemble des fonctions mesurables [1]

- $m_{\mathcal{H}}(\epsilon, \delta)$ est la fonction de complexité d'échantilon.

- $(ERM)_S$ est l'hypothèse qui minimise le risque empirique sur S, i.e.,

$$(ERM)_{\mathcal{H}}(S) = A(S) = h_S = \arg\min_{h \in \mathcal{H}} \mathcal{R}_S(h)$$

  C'est la meilleure hypothèse pour le *dataset* S.

- $(\Omega, \mathcal{E}, \mathbb{P})$ désigne un espace probabilisé

- $\mathbf{A}$ désigne une matrice.

- $\mathcal{M}_{n,p}(\mathbb{K})$ désigne l'espace des matrices de n lignes, p colonnes à coefficients dans $\mathbb{R}$

1. $(\mathcal{X}, m_{\mathcal{X}})$ et $(\mathcal{Y}, m_{\mathcal{Y}})$ sont des espaces mesurables

Rappels

1 Modèle formel de l'apprentissage statistique supervisé

1.1 Définitions générales

- Soient $\mathcal{X}, \mathcal{Y}$ donnés. La fonction de coût L est définie par :

$$\begin{aligned} L : \mathcal{Y} \times \mathcal{Y} &\to \mathbb{R}^+ \\ (y, y') &\mapsto L(y, y') \end{aligned}$$

  C'est une fonction arbitraire. En général, on prend $L(y, y') = |y - y'|^2$ (méthode OLS) avec $y' = \hat{y} = h(x)$, h l'hypothèse que l'on fait sur $x \in \mathcal{X}$ pour estimer la valeur y i.e. $\hat{y}$ est un estimateur de y. L est donc le coût de décision de h sur x.

- $h \in \mathcal{H} \subset m(\mathcal{X}, \mathcal{Y})$ avec $\mathcal{H}$ l'ensemble des hypothèses faites sur x pour estimer y.

- $S = ((x, y_i))_{1 \leq i \leq m} = ((x_1, y_1), \ldots, (x_m, y_m)) \in (\mathcal{X} \times \mathcal{Y})^*$ est une séquence d'objets labellisés. Les x_i sont les données observées et les y_i les valeurs à estimées. S représente le jeu de données d'entraînement

- Un Algorithme Automatique Supervisé (AAS) est une fonction tel que :

$$\begin{aligned} A : (\mathcal{X} \times \mathcal{Y})^* &\to \mathcal{H} \\ S &\mapsto A(S) = h_s \end{aligned}$$

- Risque réel :

$$\begin{aligned} \mathcal{R}(h) &= \mathbb{E}[L(y, y')] \\ &= \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) p(x, y) dx dy \\ &= \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) p(y|x) p(x) dx dy \end{aligned} \tag{1.1}$$

- Risque empirique :

$$\mathcal{R}_s(h) = \hat{\mathcal{R}}(h) = \frac{1}{m} \sum_{i=1}^{m} L(h(x_i), y_i) \tag{1.2}$$

C'est le seul risque dont on a accès (quantité d'information disponible limitée et finie). On cherche à minimiser le risque réel $\mathcal{R}$ à l'aide de la décision prise parmis $\mathcal{H}, h_s = A(S)$, à savoir :

$$\mathcal{R}(h_s) = \min_{h \in \mathcal{H}} \mathcal{R}(h) \Longleftrightarrow (\text{ERM})_{\mathcal{H}} = A(S) = h_s = \arg\min_{h \in \mathcal{H}} \mathcal{R}_s(h) \tag{1.3}$$

Propriété : $h \in \mathcal{H}, \mathcal{R}_s(h) \xrightarrow[m \to \infty]{p.s.} \mathcal{R}(h)$ et en moyenne quadratique. [1]

1.2 Capacité d'apprentissage PAC

1.2.1 Définition

Soient $\mathcal{X}, \mathcal{Y}, L, \mathcal{H}$ fixés. $\mathcal{H}$ a la capacité PAC [2] quand $\exists A, \exists m_{\mathcal{H}} :]0;1[^2 \to \mathbb{N}, \forall P, \forall (\epsilon, \delta) \in]0;1[^2, \forall m \geq m_{\mathcal{H}}(\epsilon, \delta), \forall S$

$$P(\mathcal{R}(h_S) - \min_{h \in \mathcal{H}} \mathcal{R}(h) \leq \epsilon) \geq 1 - \delta \quad (*)$$

De même :

$$m_{\mathcal{H}}(\epsilon, \delta) = \min\{m \in \mathbb{N} \quad \text{tel que} \quad \forall P, \forall S, \quad (*) \text{ est vérifiée}\} \tag{1.4}$$

$m_{\mathcal{H}}(\epsilon, \delta)$ est la taille minimale du *dataset* qui permet à l'algorithme d'apprendre correctement. C'est la fonction de complexité de $\mathcal{H}$ en mémoire ou en échantilon (données). Plus $\mathcal{H}$ est complexe, plus il faut de données. De même, plus ϵ, δ sont petits, plus il faut de données. Si ϵ et δ sont petits, cela veut dire que l'algorithme retourne un bon modèle avec une grande probabilité. En général, pour une classe de VC-dimension d, on prend $m_{\mathcal{H}}(\epsilon, \delta) \approx \frac{d + log(\frac{1}{\delta})}{\epsilon}$

Propriété : Soit $\epsilon > 0$, S est **ϵ-représentatif** si et seulement si pour $h_s = (ERM)_{\mathcal{H}}(S)$,

$$\mathcal{R}(h_s) - \min_{h \in \mathcal{H}} \mathcal{R}(h) \leq \epsilon \tag{1.5}$$

1. Attention : $A(S)$ est une variable aléatoire donc $\mathcal{R}(A(S)) = \mathcal{R}(h_s)$ est une VA fonction de S, on ne peut pas appliquer la loi des grands nombres.

2. Probablement Approximativement Correct. Probablement car la probabilité de l'évènement est non négligeable ($\geq 1 - \delta$), Approximativement car le minimum global n'est pas atteint mais il s'en rapproche d'une distance au plus ϵ ($\geq \epsilon$)

1.2.2 Convergence uniforme

$\mathcal{H}$ a la propriété de convergence uniforme quand $\exists m_{\mathcal{H}}^{CU} \in]0;1[^2 \rightarrow \mathbb{N}, \forall P, \forall(\epsilon,\delta) \in]0;1[^2, \forall m \geq m_{\mathcal{H}}^{CU}(\epsilon,\delta), \forall S,$

$$P(\text{S est espilon-représentatif}) \geq 1-\delta \Longleftrightarrow P(\sup_{h\in\mathcal{H}} |\mathcal{R}(h) - \mathcal{R}_S(h)| \leq \epsilon) \geq 1-\delta \quad (**)$$

Propriété : Si $\mathcal{H}$ a la propriété de CU avec $m_{H_{CU}}^{CU}$ alors $\mathcal{H}$ a la capacité PAC par $A = (ERM)_{\mathcal{H}}$ et

$$m_H(\epsilon,\delta) \leq m_H^{CU}(\frac{\epsilon}{2},\delta) \tag{1.6}$$

1.2.3 Capacité d'apprentissage PAC pour des ensemble finis ($|\mathcal{H}| < \infty$)

Lemme d'Hoeffding (1962) : pour $(X_i)_{1\geq i\geq m}$ VA i.i.d., $\mathbb{E}[X_i] = \mu, \exists a < b, a, b \in, \mathbb{R}$ tel que $P(X_i \in [a;b]) = 1$, alors, $\forall \epsilon > 0$,

$$P(|\frac{1}{m}\sum_{i=1}^{m} X_i - \mu|) \leq 2e^{\frac{-2m\epsilon^2}{(b-a)^2}} \tag{1.7}$$

On appelle cette inégalité inégalité de concentration. D'après Hoeffding, on a que $\mathcal{H}$ a la propriété de CU SSI :

$$m_{\mathcal{H}}^{CU}(\epsilon,\delta) \leq \left\lceil \frac{\log\left(\frac{2|\mathcal{H}|}{\delta}\right)}{2\epsilon^2} \right\rceil \tag{1.8}$$

et donc $\mathcal{H}$ a la capacité PAC avec

$$m_{\mathcal{H}}(\epsilon,\delta) \leq m_{\mathcal{H}}^{CU}(\frac{\epsilon}{2},\delta) \leq \left\lceil \frac{2\log(\frac{2|\mathcal{H}|}{\delta})}{\epsilon^2} \right\rceil \tag{1.9}$$

1.2.4 Capacité d'apprentissage PAC faible

$\mathcal{H}$ a la capacité d'apprentissage PAC faible quand $\exists A$ AAS, $\exists m_{\mathcal{H}} :]0;1[^2 \leftarrow \mathbb{N}, \forall(\epsilon,\delta) \in]0;1[^2, \forall m \geq m_{\mathcal{H}}(\epsilon,\delta), \forall P, \exists h \in \mathcal{H},$

- $$\mathcal{R}(h) = 0 \tag{1.10}$$
- $$P(\mathcal{R}(h_S) \geq \epsilon) \leq \delta \tag{1.11}$$

Naturellement, $\mathcal{H}$ n'as pas la CA PAC si $\mathcal{H}$ n'a pas la CA PAC faible

1.3 Dilemme biais / complexité (*underfitting vs. overfitting*)

1.3.1 Définition

Pour certains algorithmes comme les K plus proches voisins, la complexité devient énorme, ce qui nous pousse à trouver un équilibre entre la quantité de données disponibles et la performance du modèle.

$$\mathcal{R}(h_S) = \underbrace{\mathcal{R}(h_S) - \min_{h\in\mathcal{H}} \mathcal{R}(h)}_{\epsilon \text{ d'estimation}} + \underbrace{\min_{h\in\mathcal{H}} \mathcal{R}(h)}_{\epsilon \text{ approx.}} \tag{1.12}$$

$$\downarrow \qquad\qquad \downarrow$$

variance biais

- Si $|\mathcal{H}|$ est trop petit, l'espace des hypothèses n'est pas assez complexe pour trouver une hypothèse qui apprend bien les données (*underfitting*). Dans ce cas, le **biais** $\searrow$ **et la variance** $\nearrow$

- Si $|\mathcal{H}|$ est trop grand, l'espace des hypothèses est très complexe et peut coller parfaitement aux données ($\mathcal{R}_S(h) \to 0$) mais généralise mal (*overfitting*). Il a aussi besoin de plus de données. Dans ce cas, le **biais** $\nearrow$ **et la variance** $\searrow$

1.3.2 Il n'existe pas d'aprocimateur universel

Lemme 1 : Soit $m \in \mathbb{N}^*$, si $|\mathcal{X}| \leq 2m$ et $\mathcal{H} \in \mathcal{M}(\mathcal{X}, \mathcal{Y})$, alors $\forall A \in \mathcal{H}$ AAS, $\exists \mathbb{P}$ sur $\mathcal{X} \times \mathcal{Y}$ tel que :

$$\exists f \in \mathcal{H}, \quad \mathcal{R}(f) = 0$$

$$\forall S \in (\mathcal{X} \times \mathcal{Y})^* i.i.d., \quad \mathbb{E}[\mathcal{R}(S)] \geq \frac{1}{4}$$

No free lunch theorem : Avec les hypothèses du lemme précédent et $\forall A \in \mathcal{H}$ AAS, $\exists \mathbb{P}$ sur $\mathcal{X} \times \mathcal{Y}$

$$\exists f \in \mathcal{H}, \quad \mathcal{R}(f) = 0$$

$$\forall S \in (\mathcal{X} \times \mathcal{Y})^* i.i.d., \quad \mathbb{P}(\mathcal{R}[A(S)] \geq \frac{1}{8}) \geq \frac{1}{7}$$

Le *no free lunch theorem* explique que même si il existe une hypothèse de telle sorte que le problème soit parfaitement aprenable, il est fort probable que le modèle appris ait un risque non négligeable. Sans hypothèses sur $\mathbb{P}$, l'apprentissage est peu fiable.

1.4 Dimension VC (Vapnik-Chervonenkis)

1.4.1 Définitions

- On définit le **détecteur à seuil** comme étant la fonction h_a tel que :

$$\begin{aligned} h_a : \mathbb{R} &\to \{0;1\} \\ x &\mapsto h_a(x) = \mathbf{1}_{[a,+\infty)}(x) = \begin{cases} 1 & \text{si } x \geq a \\ 0 & \text{si } x < a \end{cases} \end{aligned}$$

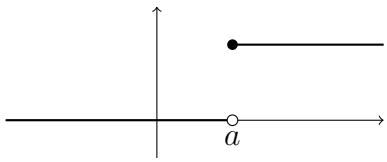

- Soit $\mathcal{C} \subset \mathcal{X}$, la restriction de $\mathcal{H}$ à $\mathcal{C}$, notée $\mathcal{H}_\mathcal{C}$ tel que

$$\mathcal{H}_\mathcal{C} = \{h/c : \mathcal{C} \to \mathcal{Y}, h \in \mathcal{H}\} \tag{1.13}$$

  Quand $\mathcal{C} = (c_1, \ldots, c_m), m < +\infty$, on idnetifie la restriction h/c d'une hypothèse h au m-uplet $(h(c_1), \ldots, h(c_m)) \in \mathcal{Y}^m$. Autrement dit, **on regarde le comportement des hypothèses $h \in \mathcal{H}$ sur les points de $\mathcal{C} \subset \mathcal{X}$ uniquement**

- Un ensemble d'hypothèses $\mathcal{H} \subset \mathcal{M}(\mathcal{X}, \{0;1\})$ brise $\mathcal{C}$ quand $\mathcal{H}_\mathcal{C}$ est l'ensemble des fonctions de $\mathcal{C}$ dans $\{0;1\}$. i.e.

$$|\mathcal{H}_\mathcal{C}| = 2^{|\mathcal{C}|} \tag{1.14}$$

  Autrement dit, $\mathcal{H}$ **brise** $\mathcal{C}$ veut dire qu'il existe dans $\mathcal{H}$ une fonction h qui est parfaitement capable de fitter les labels de $\mathcal{Y}$ sur $\mathcal{C}$. Il vient que $\mathcal{R}_S(h) = 0$ et que pour $\mathcal{C} = (c_1, \ldots, c_m), \forall y = (y_1, \ldots, y_m) \in \mathcal{Y}^m = \{0;1\}^m, \exists h \in \mathcal{H}$ tel que

$$y_i = h(x_i), \forall i \in \{1; m\} \tag{1.15}$$

la dimension VC d'un ensemble d'hypothèses $\mathcal{H}$, notée VCdim($\mathcal{H}$) est la taille maximale d'un sous-ensemble $\mathcal{C} \subset \mathcal{X}$ qui peut être brisé par $\mathcal{H}$.

$$\text{VCdim}(\mathcal{H}) = \sup\{|\mathcal{C}| \ : \ \mathcal{C} \subset \mathcal{X} \text{ est brisé par } \mathcal{H}\}. \tag{1.16}$$

Si $\mathcal{H}$ est capable de briser un espace $\mathcal{C}$ de n'importe quelle taille, $dimVC(\mathcal{H}) = +\infty$ [3]

3. on écrit sup au lieu de max dans la définition car en effet VCdim peut être infinie.