

Fiche de révision Méthodes d'estimation et Théorie moderne du Codage

Alexis GRACIAS

7 décembre 2024

Table des matières

1	Notions d'estimation	4
1.1	Rappels des cours de 1A	4
1.1.1	Espace de Hilbert	4
1.1.2	Espace L_p	4
1.1.3	Précisions	5
1.1.4	Probabilités	6
1.1.5	Schématiquement	6
1.2	Estimation	7
1.2.1	Notions et définitions de base	7
1.2.2	Point de vu Bayésien et non Bayésien	8

Introduction

Les objectifs du cours sont de présenter les bases de la théorie de la décision :

- **L'estimation pure**
- **La détection**

Plan du cours :

- Notions d'estimation
 - Introduction
 - Estimateurs bayésiens (espaces de Hilbert, projection orthogonale, estimation moyenne quadratique avec contrainte linéaire)
 - Estimateurs non bayésiens (Inégalité de Cramer-Rao, maximum de vraisemblance)
- Estimation d'un signal dans un bruit auditif
- Analyse spectrale non paramétrique
- Détection
 - Test des hypothèses (théorie bayésienne, stratégie de Neyman-Person, courbes COR)
 - Application à la détection du signal dans un bruit (décomposition de Karhunen-Loève, détection d'un signal déterminisme dans un bruit gaussien)
- Filtrage linéaire statistique
 - Introduction
 - Filtrage de Wiener
 - Filtrage de Wiener avec filtrage linéaire
- Prédiction à un pas et passé infini
 - Cas d'un signal dont la densité spectrale de puissance est bornée et admet une factorisation forte
 - Cas général, décomposition de Wold
- Interpolation d'un signal stationnaire
- Prédiction à un pas passé et infini
- Primitives de la théorie de l'information
 - Introduction (source d'information discrète, canal discret, message)
 - Deux problèmes clés de codage (codage canal, codage source distribuée)
 - Théorèmes fondamentaux (codage aléatoire (random coding), compartimentage aléatoire (random binning))
- Exercices de la théorie de l'information (2H de TD)

Prérequis :

- Cours de CIP
- Cours de Traitement du Signal
- Cours de Statistique et Apprentissage
- COurs de SIP

Chapitre 1

Notions d'estimation

1.1 Rappels des cours de 1A

1.1.1 Espace de Hilbert

Definition 1: Espaces de Hilbert

Un espace de Hilbert est un **espace préhilbertien complet**, c'est à dire un **espace de Banach** dont la norme $||.||$ découle d'un **produit scalaire** ou **hermitien** par la formule suivante :

$$||x|| = \sqrt{\langle x, x \rangle} \quad (1.1)$$

Definition 2: Espaces de Banach

Un espace de Banach est un **espace vectoriel complet et normé** sur un sous corps \mathbb{K} de \mathbb{C} (\mathbb{R} ou \mathbb{C}), peut importe la norme.

En d'autres termes, un espace de Hilbert est un espace vectoriel complet muni d'une norme définie par un produit scalaire.

1.1.2 Espace L^p

Definition 3: Espaces $L^p[a, b]$

Espace vectoriel des fonctions p intégrables au sens de **Lebesgue** sur $[a, b]$. i.e.

$$\int_a^b |f(t)|^p dt \quad (1.2)$$

converge, avec la norme L^p :

$$||f||_p = \sqrt[p]{\int_a^b |f(t)|^p dt} \quad (1.3)$$

1.1.3 Précisions

Definition 4: Espace vectoriel normé

Un K -espace vectoriel E est dit normé si il est muni d'une norme, c'est-à-dire d'une application $\mathcal{N} : E \rightarrow \mathbb{R}^+$ qui satisfait les conditions suivantes :

— **Séparation**

$$\forall x \in E, \mathcal{N}(x) = 0 \implies x = 0_E \quad (1.4)$$

— **Homogénéité**

$$\forall (x, \lambda) \in E \times \mathbb{R}, \mathcal{N}(\lambda x) = |\lambda| \mathcal{N}(x) \quad (1.5)$$

— **Sous-additivité (inégalité triangulaire)**

$$\forall (x, y) \in E^2, \mathcal{N}(x + y) \leq \mathcal{N}(x) + \mathcal{N}(y) \quad (1.6)$$

Definition 5: Espace métrique complet

Un espace métrique (E, d) est dit complet si toute suite de Cauchy ^a converge dans ce même espace, c'est-à-dire :

$$\forall n \in \mathbb{N}, (x_n)_{n \in \mathbb{N}} \in E, x_n \longrightarrow l \in E \quad (1.8)$$

^a. Suite qui vérifie le critère de Cauchy, c'est-à-dire que les éléments de la suite se rapprochent uniformément entre-eux à l'infini, i.e.

$$\forall \epsilon > 0, \exists (n_0, p_0) \in \mathbb{N}^2, \forall n > n_0, \forall p > p_0, d(x_n, x_p) < \epsilon \quad (1.7)$$

Definition 6: Espace métrique

On note (E, d) un espace métrique (E ensemble et d la distance définie pour tout éléments de E). C'est un espace vectoriel au sein duquel la notion de distance est bien définie pour tout éléments de E . L'application d satisfait les conditions suivantes :

— **Symétrie**

$$\forall (x, y) \in E^2, d(x, y) = d(y, x) \quad (1.9)$$

— **Séparation**

$$\forall (x, y) \in E^2, d(x, y) = 0 \iff x = y \quad (1.10)$$

— **Inégalité triangulaire**

$$\forall (x, y, z) \in E^3, d(x, y) \leq d(x, z) + d(z, y) \quad (1.11)$$

1.1.4 Probabilités

Definition 7: Espaces probabilisé

Un espace probabilisé est constitué d'un **espace probabilisable** et d'une **mesure de probabilité**, noté $(\Omega, \mathcal{A}, \mathbb{P})$ avec :

- Ω : l'univers, l'espace des observations ou espace des évènements élémentaires
- \mathcal{A} est une **tribu** sur Ω
- \mathbb{P} : mesure de probabilité

tel que $\mathbb{P}(\Omega) = 1$ et $\forall A \in \mathcal{A}$, $\mathbb{P}(A)$ est appelé *probabilité de l'évènement* A

Definition 8: Espaces probabilisables

Un espace probabilisable est noté (Ω, \mathcal{A}) , il est constitué de l'**univers** et de la **tribu** de cet univers.


Definition 9: Mesure de probabilité

La mesure de probabilité est définie par l'application $\mathbb{P} : \Omega \longrightarrow [0; 1]$ telle que :

- $\mathbb{P}(\Omega) = 1$
- $\mathbb{P}(\{\}) = 0$
- **σ -additivité** : \forall collection dénombrable $\{A_i\}$ d'ensemble disjoints :

$$\mathbb{P}\left(\bigcup_{i \in \mathcal{I}} A_i\right) = \sum_{i \in \mathcal{I}} \mathbb{P}(A_i) \quad (1.12)$$

1.1.5 Schématiquement



1.2 Estimation

1.2.1 Notions et définitions de base

On cherche à reconstituer un signal \underline{x} ou $\underline{\theta}$ à partir de son observation, le vecteur \underline{y} . On cherche alors une fonction $\hat{\theta}$ tel que $x \circ y = \hat{\theta}(\underline{y})$ soit la meilleure estimation de $\underline{\theta}$.

Mathématiquement, on a :

$$\begin{aligned}\underline{\theta} &= [\theta_0 \ \theta_1 \ \dots \ \theta_n], (\theta_i)_{i \in \mathbb{N}} \in G \\ \underline{y} &= [y_0 \ y_1 \ \dots \ y_n], (y_i)_{i \in \mathbb{N}} \in F\end{aligned}$$

Avec :

- $\underline{\theta}$: **paramètre décisionnel**
- \underline{y} : **vecteur d'observation**
- $(\theta_i)_{i \in \mathbb{N}}, (y_i)_{i \in \mathbb{N}}$: **variables aléatoires** de G et F
- (G, \mathcal{G}) et (F, \mathcal{F}) sont des espaces probabilisables

Estimateur

Pour un **estimateur** $\hat{\theta}$, le meilleur estimateur (ou filtre) de θ est donc l'application $\hat{\theta}$:

$$\hat{\theta} : F \longrightarrow G, \hat{\theta} \circ y = \hat{\theta}(\underline{y}) \in \mathcal{M}(F, G)$$

Avec $\mathcal{M}(F, G)$ l'ensemble des applications de F dans G .

Densité de probabilité conditionnelle

(Ω, ϵ, P) est un espace probabilisé qui modélise l'expérience aléatoire (signaux aléatoires rencontrés) \underline{y} est le vecteur d'observation qui admet une **densité** par rapport à F , de **mesure canonique**¹ ν , tandis que $\hat{\theta}(\underline{y})$ est une VA à valeurs dans G , alors la **densité de probabilité conditionnelle de \underline{y} sachant θ** s'exprime sous la forme :

$$f_{\underline{y}|\theta}(\underline{\nu}|\theta), \forall \underline{\nu} \in F$$

Fonction de perte ou de coût : application L telle que :

$$L : G \times G \longrightarrow \mathbb{R}, (\theta_1, \theta_2) \mapsto L[\theta_1, \theta_2]$$

Pour un estimateur $\hat{\theta}$ et $\underline{\nu} \in F$ donnés, $L[\hat{\theta}(\underline{\nu}), \theta]$ représente le **coût de la décision** $\hat{\theta}(\underline{\nu})$ quand la vraie valeur du paramètre décisionnel est θ . Ce coût est généralement arbitraire.

Fonction de risque

$$\mathcal{R}(\hat{\theta}, \theta) = E[L(\hat{\theta}(\underline{y}), \theta) | \theta] = \int_F L[\hat{\theta}(\underline{\nu}), \theta] f_{\underline{y}|\theta}(\underline{\nu}|\theta) d\underline{\nu}$$

1. Mesure canonique que l'on prend comme mesure de Lebesgue

1.2.2 Point de vu Bayésien et non Bayésien

- **Non Bayésien** : θ est supposé déterministe, c'est à dire qu'il obéit à des lois non probabilistes
- **Bayésien** : θ est supposé aléatoire et de loi connue
- **Paramétrique** : θ est aléatoire et de loi connue (i.e. Bayésien sans supposition)
- **Non Paramétrique** : θ est aléatoire et de loi inconnue.

Le point de vu **fréquentiste**, i.e. non paramétrique ne sera étudié dans le cadre de ce cours. Le point de vu Bayésien permet d'introduire d'autres notions telles que :

Risque moyen

pour une **densité de probabilité a fortiori** $f_\theta(u)$ du paramètre décisionnel, le risque moyen s'exprime sous la forme :

$$\overline{R}(\widehat{\theta}) = E[R(\widehat{\theta}), \theta] = \int_G R(\widehat{\theta}, u) f_\theta(u) du = \int_F H_c(\underline{\nu}) f_y(\underline{\nu}) d\underline{\nu} \quad (1.13)$$

Avec

$$H_c(\underline{\nu}) = \int_G L[\widehat{\theta}(\underline{\nu}), u] f_{\theta|y}(u|\underline{\nu}) du = E\{L[\widehat{\theta}(\underline{y}), \theta] | \underline{y} = \underline{\nu}\} \quad (1.14)$$

La ddp conditionnelle $f_{\theta|y}(u|\underline{\nu})$ devient la **densité de probabilité a posteriori** et la loi de \underline{y} est l'**evidence**